


Qwen3. 8-27B 模型结构细节图

本地检查点: Qwen3. 8-27B-w8a8 | 架构类: Qwen3.5ForConditionalGeneration

维度来自配置与全部权重分片头; 结构流程结合本地实现核对。图中层号从 1 开始, 权重 layers 索引从 0 开始。


A 整体结构与 64 层排列

主干: 文本与视觉特征合流 → 64 层 Dense Decoder → 最终 RMSNorm → 独立 LM Head



B 每个 Decoder Layer 与 SwiGLU

64 层共享该骨架; Token Mixer 由层类型选择 C 或 D。



E 视觉编码器 · 27 层 ViT + Merger

图像 / 视频共享权重; 视觉输出与语言维度对齐为 5120。




数据来源与阅读说明

主要依据: /home1/model/Qwen3. 8-27B-w8a8/config.json, quant_model_description.json、量化 YAML、权重索引及全部 safetensors 分片头。
流程核对: 本机 Transformers qwen3.5 与 SGLang qwen3.5 / qwen3.5-mtp; 名称沿用目录, 架构类以本地配置为准。
记号: B = batch; T = 语言 / 多模态序列长度; N = 合并前视觉 patch 数; Linear 用 输入维 → 输出维, 权重矩阵按 [输出维, 输入维]。
生成日期: 2026-09-22 | SVG 内嵌中文字体, 可无损放大; 精确计数、完整张量清单与复现脚本见同名 assets 目录。


C 线性注意力 · Gated DeltaNet

共 48 层: 每组的前 3 层; 不形成 T × T 注意力矩阵。




F MTP · 1 层多词元预测辅助模块

权重确实包含 mtp.*; 不计入主干的 64 层 Decoder。



D 全注意力 · Gated GQA

共 16 层: 第 4、8、12、...、64 层 (权重索引 3、7、...、63)。



G 实际量化范围与权重核验

W8A8-DYNAMIC: 权重 INT8 / per-channel, 激活 INT8 / per-token。

模块 / 权重	格式
文本 / MTP: MLP gate, up, down	W8A8
全注意力: q, k, v, o 投影	W8A8
GDN: in-proj-qkv, in-proj-z	W8A8
GDN: out, a/b, conv, norm	BF16
VisionBlock: qkv, proj, fc1	W8A8
VisionBlock fc2 / Patch / Merger	BF16
Embedding / LM Head / Norm 权重	BF16

参数元素计数 (剔除 weight_scale / weight_offset)	
主干, 含视觉 / embedding / LM Head	27.3567 B
独立 MTP 分支	0.4247 B
检查点全部模型参数	27.7814 B

INT8 参数: 23.4665 B; 浮点参数: 4.3150 B
10 个权重分片 / 2079 个张量条目 (含量化元数据)
张量数据合计: 32.129 GB (不含运行时缓存)
已逐层核验形状、dtype、索引及量化标记; 未加载权重做推理。